

AI – TECH

SKRYPT DO LABORATORIUM

Uczenie maszynowe w badaniach Ziemi

LABORATORIUM 7:

Dane sonarowe i ich przetwarzanie w badaniu i klasyfikacji dna morskiego z użyciem uczenia maszynowego. Część 2: wykorzystanie pomiarów batymetrycznych (rzeźby powierzchni dna) sonarem wielowiązkowym

Zbigniew Łubniewski



Rzeczpospolita
Polska

Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



1. Opis ćwiczenia

Wymagania wstępne:

Znajomość na bieżąco przekazywanego na zajęciach z niniejszego przedmiotu materiału, zgodnie z programem studiów

Cele ćwiczenia:

Zapoznanie się z batymetrycznymi danymi pomiarowymi dna morskiego z sonaru wielowiązkowego i przeprowadzenie klasyfikacji rodzaju dna poprzez obliczenie parametrów charakteryzujących cechy powierzchni dna morskiego w małej skali, a także wykorzystanie podstawowych technik uczenia maszynowego

Spodziewane efekty kształcenia – umiejętności i kompetencje:

1. Student jest gotów do krytycznej oceny odbieranych treści oraz uznawania znaczenia wiedzy w rozwiązywaniu problemów z zakresu metod uczenia maszynowego stosowanych w badaniu Ziemi. [K7_K02]
2. Student potrafi dokonać krytycznej analizy dostępnych rozwiązań i dobrać właściwe rozwiązanie z zakresu uczenia maszynowego dla danego zagadnienia w obserwacji i badaniu Ziemi. [K7_U09]
3. Student jest przygotowany do stałej aktualizacji i poszerzania swojej wiedzy i umiejętności w zakresie metod uczenia maszynowego stosowanych w badaniu Ziemi. [K7_U10]

Metody dydaktyczne:

Praktyczna działalność studentów - laboratorium

Zasady oceniania/warunek zaliczenia ćwiczenia

Każdy element laboratorium posiada przypisane punkty za jego wykonanie. Maksymalna liczba punktów to 5. Warunkiem zaliczenia laboratorium jest uzyskanie minimum 2.5 pkt. Niektóre elementy ćwiczenia są opcjonalne, ale pozwalają one na uzyskanie wyższej punktacji. W wyjątkowych przypadkach dopuszcza się uzyskanie przez studenta liczby punktów większej niż 5.

Wykaz literatury podstawowej do ćwiczenia:

1. [Dokumentacja oprogramowania MATLAB \(link\)](#)
2. W przypadku korzystania z oprogramowania Octave - [dokumentacja oprogramowania Octave \(link\)](#)

2. Przebieg ćwiczenia

W niniejszym punkcie krótko opisano zadania, jakie należy wykonać aby zrealizować to ćwiczenie. Bardziej szczegółowe informacje na temat tych zadań i sposobu ich wykonania zawarto w punkcie następnym.

Przed przystąpieniem do ćwiczenia należy:

1. W przypadku realizacji ćwiczenia lub części ćwiczenia na swoim komputerze należy zainstalować oprogramowanie MATLAB (lub w inny sposób uzyskać dostęp do niego). Studenci i pracownicy Politechniki Gdańskiej mają prawo nieodpłatnego użytkowania tego oprogramowania. Instrukcja nt. w jaki sposób należy to oprogramowanie pobrać oraz uaktywnić dla siebie licencję umożliwiającą jego użytkowanie, znajduje się [tutaj](#).

1a. Alternatywnie, można zainstalować sobie oprogramowanie [GNU Octave](#) i w oparciu o nie zrealizować to ćwiczenie. Octave jest w pełni zgodne z oprogramowaniem MATLAB, a przynajmniej w zakresie umożliwiającym realizację tego ćwiczenia.

2. Skopiować na swój komputer pliki potrzebne do realizacji tego ćwiczenia, udostępnione wraz z niniejszą instrukcją.

Zadania do wykonania:

1. Wczytać do MATLABa i zapoznać się ze znajdującymi się w pliku dane_z.mat zapisami wartości głębokości dna morskiego (zmienna vz) zarejestrowanymi i obliczonymi za pomocą sonaru wielowiązkowego i jego oprogramowania, dla czterech typów dna. Najlepiej wykonać to posługując się dostarczonym skryptem v_z.m. Zapoznać się z zawartością tego skryptu i poeksperymentować z wartościami detrending (= 0 lub 1, patrz opis w następnym punkcie 3. Wprowadzenie do ćwiczenia) oraz swathsector i beamsector (konieczne może być niekiedy usunięcie linii nr 29 zawierającej kod: set(gca, 'ZLim', z_zakres), np. poprzez wstawienie znaku komentarza: % na jej początek).

Punktacja: 0,5 pkt.

2. Dokonać obliczeń, dla poszczególnych sondowań, parametrów pozwalających na ich użycie w procesie klasyfikacji. Podobnie jak w poprzednim ćwiczeniu, generalnie zakładamy, że 1 „obiekt” w niniejszym zadaniu klasyfikacyjnym to jedno sondowanie, tj. 1 pozioma linia wartości głębokości w siatce jak na Rys. 2, gdzie na prawej osi poziomej są numery poszczególnych wiązek sonaru (schemat geometrii sondowania – Rys. 1), a na lewej osi poziomej – numery poszczególnych sondowań. Skrypty obliczające przykładowe parametry dla sondowań to: obl_stdh.m (obliczenie odchylenia standardowego głębokości dna dla badanego jego fragmentu), obl_sixph.m (obliczenie tzw. six-point height, tj. różnicy głębokości

między średnią dla trzech „najgłębszych” pikseli a średnią dla trzech „najpłytszych” pikseli, dla rozpatrywanego fragmentu dna).

Należy:

2a. Dokonać obliczeń różnych parametrów dla sondowań:

1) zapoznać się działaniem i wynikami ww. skryptów i dokonać obliczeń dla różnych ustawień dotyczących szczegółów ich działania, np. dla zakresu wiązek, dla których przeprowadzamy obliczenia, a także dla sytuacji gdy stosujemy tzw. detrending i gdy nie stosujemy go (patrz opis w punkcie 3. Wprowadzenie do ćwiczenia);

2) (opcjonalnie) zaproponować inne parametry charakteryzujące cechy powierzchni dna wg własnego uznania, np. oparte na funkcji autokorelacji, lub jeszcze inne, napisać skrypty obliczające je i dokonać obliczeń, zapisując wyniki w odpowiednio nazwanych zmiennych, analogicznie np. do zmiennej `var_sredniah`. Można także zdefiniować parametry, do których obliczenia potrzebny jest dwuwymiarowy, np. prostokątny podzbiór siatki głębokości, a nie tylko jedna linia – podobnie jak przy obliczaniu w poprzednim ćwiczeniu parametrów opartych na GLCM dla BSS.

Łącznie powinny być obliczone wartości przynajmniej 3 parametrów (w tym ewentualnie tych samych dla różnych ustawień, np. zakresu wiązek).

2b. Zaprezentować w sposób graficzny wyniki obliczeń parametrów:

1) za pomocą dostarczonego skryptu `rozkl2D.m`, wizualizującego rozkład wartości 2 parametrów w przestrzeni 2-wymiarowej, dla poszczególnych typów dna,

2) (opcjonalnie) w inny sposób, za pomocą samodzielnie napisanych skryptów, używając np. histogramu wartości dla pojedynczego parametru, ewentualnie wykresu wizualizującego rozkład wartości 3 parametrów w przestrzeni 3-wymiarowej, itp.

Punktacja: 2a1) – 0,5 pkt., 2a2) – od 0,5 do 1 pkt., 2b1) – 0,5 pkt., 2b2) – 0,5 pkt.

3. Przeprowadzić klasyfikację nadzorowaną typów dna używając danego klasyfikatora (klasyfikatorów), wybranych zestawów parametrów, określając podział danych na zbiór uczący i testowy itp. Wyniki przedstawić w postaci macierzy niezgodności (confusion matrix). Dostarczony skrypt `kl_min_dist_2D.m` realizuje to zadanie dla 2 wybranych parametrów (zmiennych), z użyciem klasycznego klasyfikatora minimalnoodległościowego.

Należy:

3a. Przeprowadzić klasyfikację minimalnoodległościową w różnych wersjach – dla różnych zestawów par parametrów, różnych rozmiarów zbioru uczącego i testowego itp.

3b. (opcjonalnie) Pisząc własne skrypty i modyfikując istniejące, przeprowadzić klasyfikację minimalnoodległościową dla zestawu parametrów większego niż 2, a także, ewentualnie, przeprowadzić klasyfikację używając innego klasyfikatora bądź klasyfikatorów. Można także łącznie użyć do klasyfikacji parametrów obliczonych w niniejszym ćwiczeniu oraz parametrów obliczonych w ćwiczeniu poprzednim (założyć przy tym, że dane zawarte w pliku

dane_bss.mat oraz w pliku dane_z.mat dotyczą dokładnie tych samych obszarów dna morskiego).

Punktacja: 3a – 0,5 pkt., 3b – od 0,5 do 1 pkt.


4. Przeanalizować i krótko skomentować uzyskane wyniki.

Punktacja: od 0,5 do 1 pkt.

Opcjonalne części zadań dotyczą samodzielnego napisania własnych skryptów, z założeniem samodzielnego posługiwania w tym celu dokumentacją oprogramowania MATLAB lub Octave w razie potrzeby.

3. Wprowadzenie do ćwiczenia

Sonar wielowiązkowy to urządzenie hydroakustyczne, które rejestruje w pojedynczym sondowaniu cały zbiór ech od dna morskiego lub innych elementów środowiska wodnego, tak jakby wysyłany był cały wachlarz bardzo wąskich wiązek w kierunku dna, pod różnymi kątami (w płaszczyźnie prostopadłej do kierunku płynięcia jednostki) – Rys. 1.



Rys. 1. Schematycznie przedstawiona geometria sondowania toni wodnej i dna morskiego sonarem wielowiązkowym

Oprócz innych danych, np. wartości siły rozpraszania wstecznego – backscattering strength (BSS) używanych w poprzednim ćwiczeniu, sonar wielowiązkowy, wyposażony w odpowiednie elementy swojego zestawu pomiarowego, jak wysokiej dokładności odbiornik GPS czy przechyłomierz, a także w odpowiednie oprogramowanie, potrafi dostarczyć także wysokorozdzielczych danych na temat rozkładu głębokości w obrębie sondowanego obszaru dna morskiego.

Można powiedzieć, że w pewnym zakresie, sonar działa tu dość podobnie jak skaner lidarowy: ponieważ wiadomo w którym kierunku została wysłana dana wiązka i po jakim czasie przyszło odpowiadające jej echo od dna, czyli znamy kierunek i odległość w jakiej w stosunku do przetwornika sonaru znajduje się fragment dna, który spowodował powstanie echa. Możemy więc dla każdej wiązki w każdym sondowaniu obliczyć położenie, czyli również głębokość dna. Pewnych zabiegów wymaga oczywiście jeszcze przejście od nieregularnej chmury punktów (x, y, z) do siatki głębokości $z = f(x, y)$, gdzie x i y przyjmują wartości odpowiadające położeniu węzłów regularnej siatki.

Należy oczywiście mieć świadomość, że istnieją różne czynniki zniekształcające wspomniany wyżej pomiar: niejednorodność właściwości akustycznych ośrodka wodnego powodująca refrakcję i tym samym zakrzywienie linii rozchodzenia się fali akustycznej i w konsekwencji komplikację geometrii pomiaru, niedoskonałość odbiornika nawigacji satelitarnej, czy kołysanie się jednostki pływającej. Stosuje się więc różnorakie metody kompensacji czynników wprowadzających zniekształcenia, nie zawsze daje to jednak wystarczająco dobre rezultaty.


Skrypt `v_z.m` rysuje 4 rysunki-wykresy będące trójwymiarowymi wizualizacjami siatek rzeźby dna, każdy dla 1 typu dna. Typy dna są następujące (takie same jak w poprzednim ćwiczeniu): 1 – muł, 2 – mieszanina mułu, piasku i odpadów antropogenicznych, 3 – piasek drobnoziarnisty, 4 – piasek gruboziarnisty. Dane zostały zarejestrowane sonarem Kongsberg EM 3002 w rejonie Zatoki Gdańskiej.

Siatkę głębokości dla przykładowego typu dna przedstawiono na Rys. 2. Wykres tego rodzaju tworzy skrypt `v_z.m`, wczytując plik `dane_z.mat`, w którym znajduje się zmienna `vz` – trójwymiarowa tablica wartości głębokości w metrach, o rozmiarach: liczba typów dna (= 4), liczba sondowań (= 600), liczba wiązek (= 160). Jedna pozioma linia idąca ukośnie w prawo do góry na wykresie przedstawia dane batymetryczne dla jednego sondowania, dla „wachlarza” wiązek, 1 piksel to wartość głębokości dna dla 1 wiązki. Na prawej osi poziomej znajdują się numery poszczególnych wiązek sonaru, a na lewej osi poziomej – numery poszczególnych sondowań.

Jeżeli zaobserwujemy różnicę, jaka występuje przy stosowaniu lub nie operacji detrendingu (zmienna: `detrending = 0` lub `1` w skrypcie `v_z.m`), to w nawiązaniu do tego co zostało napisane wyżej, możemy dostrzec różne niedoskonałości niniejszego pomiaru głębokości dna, np. (fikcyjnego) „falowania” powierzchni dna w rytm kołysania się jednostki pływającej.

Detrending polega na znalezieniu równania prostej aproksymującej liniowo przebieg głębokości dla badanego wektora wartości (u nas – wybranej linii w siatce głębokości wzdłuż prawej osi poziomej) czyli linii trendu (funkcja MATLABa polyfit) i odjęciu tej liniowej funkcji aproksymującej od przebiegu wartości głębokości. Czyli, dla każdego sondowania „wypłaszczamy dno” i pozbywamy się tym samym niektórych zniekształceń widocznych w większej skali. Tym samym pozbywamy się też informacji wprost o głębokości dna w danym miejscu.

Z uwagi na obecność w omawianych pomiarach batymetrycznych czynników zniekształcających powierzchnię dna w większej skali i stosowanie przez nas detrendingu, obliczane parametry charakteryzujące powierzchnię dna powinny raczej koncentrować się na jego cechach w małej skali. Nie powinny także używać wartości głębokości wprost, ponieważ dany typ powierzchni dna może występować na różnych głębokościach i głębokość wprost na ogół nie jest parametrem charakteryzującym rodzaj dna (w tym kontekście należy zauważyć, że przykładem nt. „czego nie należy liczyć i używać” jest tu do pewnego stopnia wartość obliczana przez skrypt obl_sredniah.m dla detrending = 0).



Rys. 2. Wizualizacja 3D siatki głębokości dna morskiego otrzymanej z pomiarów sonarem wielowiązkowym (wymiały w metrach)

Biorąc pod uwagę, że podobnie jak w przypadku poprzedniego ćwiczenia dysponujemy niewielką ilością danych – maksymalnie 600 sondowań dla jednego typu dna, trudno byłoby przeprowadzić efektywne uczenie w przypadku bardziej zaawansowanych metod uczenia maszynowego. Tak samo jak poprzednio użyjemy więc prostych metod klasyfikacji.

Gdy chodzi o obliczanie parametrów, skrypty w rodzaju `obl_stdh.m` liczą wartości tych parametrów dla poszczególnych sondowań i wynik zapisują w postaci 2-wymiarowej tablicy o rozmiarach: liczba typów dna (4), liczba obiektów (maksymalnie 600 dla każdego typu dna).


Można też zaproponować inne parametry charakteryzujące cechy powierzchni dna wg własnego uznania, np. oparte na funkcji autokorelacji, lub jeszcze inne, napisać skrypty obliczające je i dokonać obliczeń, zapisując wyniki w odpowiednio nazwanych zmiennych, analogicznie np. do zmiennej `var_stdh`. Można poszukać się tu np. następującą [publikacją](#) gdy chodzi o parametry charakteryzujące lokalną nieregularność i kształt powierzchni (artykuł ten jest co prawda z innej dziedziny, ale podaje wiele interesujących parametrów charakteryzujących cechy powierzchni danej np. w postaci siatki). Można także zdefiniować parametry, do których obliczenia potrzebny jest dwuwymiarowy, np. prostokątny podzbiór siatki głębokości, a nie tylko jedna linia – podobnie jak przy obliczaniu w poprzednim ćwiczeniu parametrów opartych na GLCM dla BSS.

Skrypt `rozkl2D.m` (taki sam jak w poprzednim ćwiczeniu) tworzy wykres i wizualizuje na nim rozkład wartości 2 parametrów w przestrzeni 2-wymiarowej, dla poszczególnych typów dna. W skrypcie tym należy odpowiednie zmienne podstawić pod `zm1` i `zm2`. Przykładowy wynik działania tego skryptu przedstawiony został na Rys. 3. Jak widać, w przedstawionym na tym rysunku przypadku wartości parametrów dla poszczególnych klas nakładają się na siebie, należy więc, proponując i obliczając inne parametry, podjąć próbę poprawy tej sytuacji.

Można także zaprezentować wyniki obliczeń parametrów w inny sposób, za pomocą samodzielnie napisanych skryptów, używając np. histogramu wartości dla pojedynczego parametru, bądź wizualizując rozkład wartości 3 parametrów w przestrzeni 3-wymiarowej, itp.

Również tak jak w poprzednim ćwiczeniu, skrypt `kl_min_dist_2D.m` realizuje klasyfikację minimalnoodległościową. Zakłada on, że w klasyfikacji używane są tylko 2 parametry (zmienne) i należy je podstawić pod `zm1` i `zm2`, tak jak w skrypcie `rozkl2D.m`. Skrypt `kl_min_dist_2D.m` generuje wyniki poprzez podanie macierzy niezgodności (confusion matrix) klasyfikacji, w 2 formach: 1) z podaniem ilości obiektów dla każdej klasy, które zostały sklasyfikowane do poszczególnych klas, 2) z podaniem procentowego udziału obiektów dla każdej klasy, które zostały zakwalifikowane do poszczególnych klas. Wartości na głównej

przekątnej macierzy niezgodności oznaczają tzw. dokładność użytkownika dla przeprowadzonej klasyfikacji, tj. jaki % obiektów należących w rzeczywistości do danej klasy został sklasyfikowany poprawnie, czyli do tej właśnie klasy. Skrypt oblicza także łączny procentowy udział wszystkich poprawnych klasyfikacji w łącznej liczbie wszystkich klasyfikacji.



Rys. 3. Rozkład w przestrzeni dwuwymiarowej zbioru wartości obliczonych 2 parametrów dla sondowań, dla czterech typów dna: odchylenie standardowe głębokości dna vs. six-point height

Można także, pisząc własne skrypty i modyfikując istniejące, przeprowadzić klasyfikację minimalnoodległościową dla zestawu parametrów większego niż 2, a także przeprowadzić klasyfikację używając innego klasyfikatora bądź klasyfikatorów. Wyniki klasyfikacji należy podawać tak samo jak odbywa się to w skrypcie `kl_min_dist_2D.m`.

Można również łącznie użyć do klasyfikacji parametrów obliczonych w niniejszym ćwiczeniu oraz parametrów obliczonych w ćwiczeniu poprzednim (założyć przy tym, że dane zawarte w pliku `dane_bss.mat` oraz w pliku `dane_z.mat` dotyczą dokładnie tych samych obszarów dna morskiego).

4. Forma i zawartość sprawozdania

Sprawozdanie z realizacji laboratorium powinno zawierać (patrz: Zadania do wykonania w punkcie 2. Przebieg ćwiczenia):

- 1 – wizualizacje trójwymiarowe siatek powierzchni dna (generowane np. przez skrypt v_z.m) dla poszczególnych typów dna, ewentualnie z krótkim komentarzem).
- 2 – graficzne przedstawienie otrzymanych rozkładów wartości parametrów, z krótkim opisem, a w przypadku stworzenia własnych skryptów, należy zamieścić także kod tych skryptów.
- 3 – przedstawienie poszczególnych wyników klasyfikacji, w sposób, w jaki robi to skrypt kl_min_dist_2D.m, z krótkim opisem. W przypadku stworzenia własnych skryptów, realizujących np. inne metody klasyfikacji, zamieścić należy także ich kod.
- 4 – przedstawienie (krótkiej) dyskusji wyników oraz wniosków.

Dodatki

Brak.